

Лабораторна робота № 6.

Кластеризація даних

Короткі теоретичні відомості. Кластерний аналіз (англ. Data clustering) – задача розбиття заданої вибірки об'єктів (ситуацій) на підмножини, що називаються кластерами, так, щоб кожен кластер складався з схожих об'єктів, а об'єкти різних кластерів істотно відрізнялися [5-7].

Кластеризацію можна здійснювати двома основними способами: за допомогою ієрархічних чи ітераційних процедур.

Ієрархічні процедури – послідовні дії щодо формування кластерів різного рангу, підпорядкованих між собою за чітко встановленою ієрархією. Найчастіше ієрархічні процедури здійснюються шляхом агломеративних (об'єднувальних) дій. Вони передбачають такі операції:

1. Послідовне об'єднання подібних об'єктів з утворенням матриці подібності об'єктів;
2. Побудова дендрограми (деревоподібної діаграми), яка відображає послідовне об'єднання об'єктів у кластери; формування із досліджуваної сукупності окремих кластерів на першому початковому етапі аналізу та об'єднання всіх об'єктів в одну велику групу на завершальному етапі аналізу.

Ітераційні процедури полягають в утворенні з первинних даних однорівневих (одного рангу) ієрархічно не підпорядкованих між собою кластерів.

Нейромережеві алгоритми кластеризації.

Одним з ефективних напрямків вирішення задачі як класифікації так і кластеризації даних є використання нейромереж [1-4]. На відміну від задач класифікації ми не маємо жодної інформації а ні про кількість кластерів, а ні про область їх розташування. Тому не можемо сформувати навчаючі пари і відповідно звести задачу до мінімізації функціонала похибки. У даному випадку мережа “змушена” навчатися на самій вхідній множині даних. При відсутності зовнішньої мети “вчителем” мережі можуть бути лише самі дані, а саме закономірності, котрі відрізняють їх від шуму. Такий тип навчання

називається навчанням без “вчителя”. Для багатьох задач кластеризації даних використовуються одношарові нейронні мережі що складаються з нейронів-індикаторів. Математична модель нейрона-індикатора показана на рисунку 6.1.




Рис.6.1. Математична модель нейрона-індикатора

Після відповідного навчання нейрона (корекції ваг за набором прикладів $\{\vec{x}^n\}$) амплітуда його виходу може бути індикатором того, наскільки даний вхідний вектор відповідає навчаючому набору. Іншими словами, нейрон може стати індикатором приналежності вхідної інформації до заданої групи прикладів.

Правило навчання окремого нейрона-індикатора є локальним, оскільки базується тільки на інформації безпосередньо доступній самому нейрону – значеннях його входів і виходів.

Правило навчання мережі з обмеженням величини росту ваг дістало назву правило навчання Ойа. Значення величин корекції ваг при подачі на вхід нейрона i -того вектора $\vec{x}_i$ визначаються рівнянням у векторній формі $\Delta \vec{w} = \eta y_i (\vec{x}_i - y_i \vec{w})$. Таке правило максимізує чутливість виходу нейрона при обмеженій амплітуді ваг.

Розглянемо приклад мережі, котра проводить кластеризацію двовимірних вхідних векторів на два кластери. Структура такої мережі показана на рисунку 6.2.




Рис.6.2. Структура двонейронної мережі для кластеризації даних

Значення виходів мережі y_i визначаються залежностями:

$$y_1 = w_{11}x_1 + w_{21}x_2$$

$$y_2 = w_{12}x_1 + w_{22}x_2.$$

Або у векторній формі:

$$\vec{y} = W\vec{x}$$

Зазвичай, вхідні вектори нормуються: $|\vec{x}| = 1$. Нормування вхідного вектора можна провести шляхом перерахунку його компонент: $x_j = \frac{x_j}{\sqrt{\sum_{i=1}^d x_i^2}}$,

де d розмірність вхідних даних (для нашого прикладу $d = 2$). Допустимо, що множина вхідних векторів є сукупністю двох множин C_1 та C_2 , вектори у яких розподілені, наприклад, згідно закону Гауса (або по іншому закону). Графічно це зображено на рисунку 12.3, там же показано початкові положення векторів ваг нейронів $\vec{w}_1, \vec{w}_2$ положення яких вибирається випадково.




Рис 12.3. Положення вхідних нормованих векторів $\vec{x}_i^{c_i}$ та початкові положення векторів ваг $\vec{w}_i$

Допустимо, першим на вхід мережі подається вектор $\vec{x}_1^{c_1}$ з множини C_1 . Очевидно, його векторний добуток з $\vec{w}_1$ буде більшим за векторний добуток з $\vec{w}_2$, тому $y_1 > y_2$ і перший нейрон буде „переможцем”. Його вихід приймається рівним 1 а виходи решти нейронів вважаються рівними нулю.

Далі використовується алгоритм навчання як і для шару Ойа [1], з врахуванням значень виходів. Тоді ваги нейронів, котрі програли, не коректуються (бо для них $y_i = 0$), а для „переможця” величина корекції вектора ваг визначається наступним чином: $\Delta \vec{w}_j = \eta y_j (\vec{x} - \sum_k y_k \vec{w}_k) = \eta y_j (\vec{x} - y_j \vec{w}_j) = \eta (\vec{x} - \vec{w}_j)$. У випадку перемоги першого нейрона матимемо:

$$\begin{aligned} \Delta w_{11} &= \eta (x_1 - w_{11}) \\ \Delta w_{21} &= \eta (x_2 - w_{21}) \end{aligned}$$

Згідно цього алгоритму прирости ваг будуть коректувати вектор ваг таким чином, щоб він співпадав за напрямком з вхідним вектором.

Якщо подати вхідний вектор з другої множини C_2 , то „переможцем” буде другий нейрон і буде коректуватись тільки вектор ваг другого нейрона $\vec{w}_2$. Очевидно, при подачі серії векторів з обох множин, вектори ваг нейронів

будуть орієнтовані в напрямках близьких до векторів математичних сподівань множин c_1 та c_2 . Отже, після навчання мережа буде видавати на виході сигнал

$$\vec{y} = \begin{pmatrix} 1 \\ 0 \end{pmatrix}, \text{ якщо вхідний вектор належить множині сигналів } c_1 \text{ і сигнал } \vec{y} = \begin{pmatrix} 0 \\ 1 \end{pmatrix},$$

якщо вхідний вектор належить множині c_2 . Іншими словами, мережа проведе кластеризацію даних. З другого боку, таку процедуру можна назвати оцифруванням сигналу.

У деяких літературних джерелах такого типу мережі (нейрони) називають мережами Кохонена (на ім'я фінського науковця – автора такого типу мереж). Мережі такого типу і алгоритми їх навчання мають дві слабкі сторони:

- часто ми не знаємо на скільки класів можна розбити вхідні дані і тому не можемо адекватно вибрати структуру мережі (кількість нейронів у шарі).
- постає проблема вибору початкових напрямків ваг. Може статися так, що внаслідок невдалого вибору початкових значень ваг деякі нейрони завжди будуть програвати і по-суті будуть „мертвими” (не будуть приймати участі в процедурі кластеризації вхідних даних), а інші – навпаки завжди виграватимуть.

Для усунення цих недоліків існують спеціальні алгоритми, котрі в тій чи іншій мірі вільні від згаданих недоліків [3].

Завдання

Вихідні набори векторів для навчання нейромережі отримуємо з розділу файли команди Teams: Завдання_Лаб6_ файл №.xlsx № відповідає номеру студента в журналі обліку ВИКЛАДАЧА.

Для нейромережевого алгоритму кластеризації провести дослідження результатів кластеризації від початкових значень ваг.

У звіті з лабораторної роботи необхідно подати:

- Результати візуалізації вхідних даних

- Результати кластеризації класичним алгоритмом з візуалізацією результатів та привести характеристики отриманих кластерів при різних значеннях параметрів.
- Результати кластеризації нейромережовим алгоритмом з візуалізацією результатів та привести характеристики отриманих кластерів.

Результатії необхідно надати у вигляді графіків на яких повинні бути зображено вектори кластерів розфарбовані різними кольорами в залежності від приналежності до певного кластера.

Література:

1. Любунь З. М. Основи теорії нейромереж / З. М. Любунь /: Текст лекцій. – Львів: Видавничий центр ЛНУ імені Івана Франка, 2007. –142 с.
2. Добровська Л. М. Теорія та практика нейронних мереж : навч. посіб. / Л. М. Добровська, І. А. Добровська. – К. : НТУУ «КПІ» Вид-во «Політехніка», 2015. – 396 с.
3. Субботін С. О. Нейронні мережі : теорія та практика: навч. посіб. / С.О.Субботін. – Житомир: Вид.О. О. Євенок, 2020. – 184 с.
4. Любунь З., Русин Б., Луцик О. Особливість навчання мережі Кохонена на основі методу нейроядерної ентропії при стиску зображень / З. Любунь, Б. Русин, О. Луцик // “Радіоелектроніка та інформатика”. –2007. – №1. – С. 69-72.
5. Черняк О. І., Захарченко П. В. Інтелектуальний аналіз даних: Підручник. Київ, 2014.
6. Теорія економічного аналізу. [Електронний ресурс]. – Режим доступу: http://pidruchniki.com/11800912/ekonomika/klasterniy_analiz. – Дата звернення: 14.04.2015.
7. [Кластерний аналіз економіки Львова - Проект РЕОП](#). [Електронний ресурс]. – Режим доступу: http://www.ebed.org.ua/sites/expertise.one2action.com/files/repo/lviv_1811_final.pdf. – Дата звернення: 14.04 .2015.